بند إضافي: أفضل نماذج الذكاء الاصطناعي وأفضل شبكة عصبية، وتدريب عدة نماذج ومقارنتها واختيار الأفضل

أ. لماذا نقارن عدة نماذج؟

لا يوجد نموذج واحد هو الأفضل دائماً. فبيانات هذا المشروع جدولية وغير متوازنة (الاحتيال غالباً أقل من ١٪ من العمليات)، وتحمل ثلاثة أنواع من الإشارات: جدولية وتسلسلية وعلاقاتية. لذلك يدرّب المشروع عدة نماذج على البيانات نفسها وبالتقسيم نفسه، ثم يقارنها بمقاييس موحدة ويعتمد الأفضل بالأرقام.

ب. النماذج المرشحة

النموذج	النوع	الإشارة التي يخدمها	المزايا	العيوب
Logistic Regression	خطي	جدولية	بسيط وسريع ومفسَّر؛ يصلح خطاً أساسياً (Baseline)	لا يلتقط العلاقات غير الخطية
Random Forest	أشجار قرار	جدولية	مستقر ومقاوم للضجيج	أبطأ وأكبر حجماً من Boosting
XGBoost / LightGBM / CatBoost	Gradient Boosting	جدولية	غالباً الأقوى على البيانات الجدولية؛ سريع؛ يتعامل مع عدم التوازن؛ يُفسَّر بـ SHAP	لا يرى العلاقات بين الحسابات مباشرة
Isolation Forest / Autoencoder	كشف شذوذ بلا وسوم	جدولية	يكتشف أنماطاً جديدة لم تظهر في التدريب؛ يفيد عند قلة الوسوم	إنذارات كاذبة أكثر؛ أضعف من النماذج الموسومة
MLP	شبكة عصبية أمامية	جدولية	مرجع عصبي للمقارنة ويمكن دمجه مع Embeddings	لا يتفوق غالباً على Boosting في الجداول

تحتاج بيانات أكثر وأصعب في التفسير	تفهم ترتيب الأحداث وسرعتها	تسلسلية: دخول ثم تغيير جوال ثم مستفيد ثم تحويل	شبكة تسلسلية	GRU / LSTM (أو Transformer)
تتطلب بيانات موسومة كبيرة وإعداداً أعقد	تكشف شبكات الوسطاء والأجهزة المشتركة	علاقاتية: حسابات وأجهزة وعناوين IP	شبكة عصبية بيانية (GNN)	GraphSAGE / GAT / R-GCN
أعقد وأبطأ وأصعب في الصيانة	يجمع نقاط قوة النماذج	كل الإشارات	تجميعي	Stacking Ensemble

ج. أفضل شبكة عصبية للمشروع

لا توجد شبكة عصبية واحدة هي الأفضل في كل شيء، والجواب يعتمد على نوع الإشارة:

- للعلاقات بين الحسابات والأجهزة: GraphSAGE (أو GAT) على رسم غير متجانس من الحسابات والأجهزة وعناوين IP. وهي المرشحة الأولى لأنها استقرائية (Inductive)، أي تستطيع تقييم حساب جديد لم تره أثناء التدريب دون إعادة تدريب كاملة، وهذا مهم لأن حسابات الوسطاء تُنشأ باستمرار.
- لتسلسل السلوك: GRU، لأنها أخف من LSTM وتحتاج بيانات أقل من Transformer.
- للبيانات الجدولية: MLP كمرجع للمقارنة فقط.
- التركيب الموصى به (فرضية تُختبر): نموذج هجين، يولّد فيه GraphSAGE تمثيلاً (Embedding) لكل حساب وجهاز، ويولّد GRU تمثيلاً لتسلسل الأحداث الأخير، ثم تُضاف التمثيلات إلى الخصائص الجدولية وتُغذّى إلى XGBoost أو LightGBM كنموذج نهائي. وهذا يجمع قوة الشبكات العصبية في العلاقات والتسلسل مع قوة Boosting في الجداول.

تنبيه علمي: الشبكات البيانية والـ Transformers تحتاج عادةً إلى ١٠٠ ألف عملية موسومة على الأقل، والأفضل ٥٠٠ ألف فأكثر. لذلك يجب أن ينتج مولّد البيانات حجماً كافياً، وأن تُختبر النتائج أيضاً على مجموعات بيانات عامة، لأن نتائج البيانات الاصطناعية قد تكون متفائلة.

د. منهجية التدريب والمقارنة

١. تجهيز البيانات: تنظيف وترميز وحساب الخصائص بالطريقة نفسها لكل النماذج.
٢. التقسيم الزمني (Temporal Split): التدريب على الأقدم (٧٠٪)، والتحقق (١٥٪)، والاختبار على الأحدث (١٥٪)، لتجنب تسرب المعلومات من المستقبل.

٣. معالجة عدم التوازن: أوزان الفئات (Class Weights) أو Focal Loss أو أخذ عينة من الفئة الكبيرة، ويُطبَّق SMOTE (إن استُخدم) على بيانات التدريب فقط.
٤. ضبط المعاملات: باستخدام Optuna بعدد محاولات ثابت لكل نموذج وتحقق زمني متدحرج (Rolling Validation).
٥. تعدد التشغيلات: التدريب بعدة بذور عشوائية (٣ إلى ٥) لقياس استقرار النتائج.
٦. معايرة الاحتمالات: Isotonic أو Platt لتصبح الدرجة معبّرة عن احتمال حقيقي وتصلح لتحديد الحدود.
٧. التقييم الموحد: تقييم كل النماذج على مجموعة الاختبار نفسها وحفظ النتائج في جدول model_runs.
٨. المقارنة والاختيار: حسب المعايير الموزونة أدناه، مع استبعاد أي نموذج يتجاوز حد زمن الاستجابة من مسار الزمن الحقيقي.
٩. التفسير والاختبار: SHAP، واختبار على سيناريو الاستيلاء الكامل، وعلى IEEE-CIS وPaySim.
١٠. الترقية: يصبح النموذج الأفضل نموذج الإنتاج (Champion)، ويعمل المنافس بصمت (Shadow Mode) فترة قبل أي استبدال.

هـ. معايير المقارنة والأوزان

الوزن	لماذا	المقياس
30%	المقياس الرئيسي مع البيانات غير المتوازنة	PR-AUC (Average Precision)
20%	كم احتيالاً نكتشف دون إغراق المحللين بإنذارات كاذبة	Recall عند Precision ثابتة (مثلاً 90%)
15%	جودة أول K تنبيه، حيث K هو ما يستطيع المحللون مراجعته يومياً	Precision@K
10%	قدرة المحلل على فهم السبب	قابلية التفسير
10%	شرط للعمل اللحظي	زمن الاستجابة (p95)
10%	تذبذب النتائج عبر البذور العشوائية وعبر الفترات الزمنية	الاستقرار
5%	زمن التدريب والذاكرة	كلفة الموارد

الدرجة النهائية = مجموع (الوزن × القيمة المقيّسة لكل مقياس). وتُعرض أيضاً ROC-AUC وF1 وF2 ومصفوفة الالتباس، ولا تُعتمد الدقة (Accuracy) لأنها مضللة عندما يكون الاحتيال أقل من ١٪ من العمليات. ويُضاف مقياس أثر الأعمال: قيمة المبالغ الموقوفة مطروحاً منها كلفة مراجعة التنبيهات. وشرط الإقصاء: النموذج الذي يتجاوز زمن الاستجابة المحدد (٣٠٠ ملّي ثانية) لا يدخل مسار الزمن الحقيقي.

و. قالب جدول النتائج (يُملأ بعد التجارب)

النموذج	PR-AUC	Recall عند Precision 90%	Precision@K	زمن الاستجابة p95	الدرجة النهائية
Logistic Regression (خط أساس)	—	—	—	—	—
Random Forest	—	—	—	—	—
XGBoost	—	—	—	—	—
LightGBM	—	—	—	—	—
CatBoost	—	—	—	—	—
Isolation Forest	—	—	—	—	—
MLP	—	—	—	—	—
GRU	—	—	—	—	—
GraphSAGE	—	—	—	—	—
الهجين: GraphSAGE + GRU + LightGBM	—	—	—	—	—

ز. النتيجة المتوقعة (فرضية)

يُتوقع أن تتفوق نماذج Gradient Boosting على الخصائص الجدولية وحدها، وأن يرفع دمج تمثيلات GraphSAGE نسبة الاكتشاف تحديداً في حالات حسابات الوسطاء والأجهزة المشتركة. لكن هذه فرضية يحسمها التنفيذ؛ فإن لم يتفوق النموذج الهجين بفارق يبرر تعقيده، يُعتمد النموذج الأبسط الأفضل أداءً.

ح. تنفيذ المقارنة داخل المشروع

- سكربتات تدريب بلغة Python تنتج لكل نموذج ملفه المدرَّب (joblib أو ONNX) ومقاييسه.
- جدول model_runs في قاعدة البيانات، ولوحة في Laravel (المتطلب DS-05) تعرض المقارنة.
- زر ترقية النموذج إلى Champion (المتطلب DS-06) مع تسجيل العملية في سجل التدقيق.